

Eksamen på Økonomistudiet vinteren 2019-20

Sandsynlighedsteori og Statistik

2. årsprøve

4. januar, 2020

(3-timers prøve med hjælpemidler)

Rettevejledning

Opgave 1

1. Sandsynligheden for at Bent ankommer til den manglende lift på tur i er $P(X_i = 1) = p = \frac{1}{90}$.
2. Lad $Y = \sum_{i=1}^{25} X_i$ angive antallet af gange, Bent har mødt den manglende lift nummer 43 ud af sine 25 uafhængige ture. Y er således Binomial-fordelt, $Y \sim \text{Bin}(25, \frac{1}{90})$. Sandsynligheden for, at Bent møder den manglende lift 3 gange ud af sine 25 ture er

$$\begin{aligned} P(Y = 3) &= \binom{25}{3} \frac{1}{90^3} \left(\frac{89}{90}\right)^{22} \\ &= \frac{25!}{22! \cdot 3!} \frac{1}{90^3} \left(\frac{89}{90}\right)^{22} \\ &\approx 0.0025. \end{aligned}$$

3. Sandsynligheden for, at Bent møder den manglende lift mindst 1 gang på sine 25 ture er

$$\begin{aligned} P(Y \geq 1) &= 1 - P(Y < 1) \\ &= 1 - P(Y = 0) \\ &= 1 - 0.7563 \\ &= 0.2437 \end{aligned}$$

da $P(Y = 0) = \left(\frac{89}{90}\right)^{25} \approx 0.7563$.

4. Vi har nu, at der er to manglende lifter på de sidste 10 ture. Vi lader antallet af gange, Bent møder den manglende lift 2 være angivet ved Z . Vi har at Z også er binomial-fordelt med $Z \sim \text{Bin}(10, \frac{1}{90})$. Vi ved, at

$$\begin{aligned} \mathbb{E}[Y] &= 25 \cdot \frac{1}{90} = \frac{5}{18} \\ \mathbb{E}[Z] &= 10 \cdot \frac{1}{90} = \frac{1}{9} \end{aligned}$$

sådan at middelværdien af det samlede antal ture, $M = Y + Z$, hvor Bent har mødt en manglende lift, er

$$\mathbb{E}[M] = \mathbb{E}[Y] + \mathbb{E}[Z] = \frac{35}{90} = \frac{7}{18} \approx 0.3889$$

(Bemærk, da Y og Z IKKE er uafhængige, kan vi ikke sige, at $M \sim \text{Bin}(35, \frac{1}{90})$)

Opgave 2

1. Middelværdien er

$$\begin{aligned}\mathbb{E}[Y] &= \int_1^5 (6x + 4)p(x)dx \\ &= \int_1^5 (6x + 4)\frac{1}{4}dx \\ &= \left[\frac{3}{4}x^2 + x\right]_1^5 \\ &= 75/4 + 5 - (3/4 + 1) \\ &= 72/4 + 4 \\ &= 22\end{aligned}$$

2. Denne opgave kan løses som ovenover ved at beregne $\mathbb{E}[Y^2] = \int_1^5 (6x + 4)^2 p(x)dx$ og bruge dette i $\text{Var}(Y) = \mathbb{E}[Y^2] - \mathbb{E}[Y]^2$. Alternativt, så kan svaret findes ved at finde variansen af X og så bruge regneregler for varians:

$$\mathbb{E}[X] = 3 \text{ (midtpunkt i uniform)}$$

$$\begin{aligned}\mathbb{E}[X^2] &= \int_1^5 x^2 p(x)dx \\ &= \frac{1}{4} \int_1^5 x^2 dx \\ &= \frac{1}{4} \left[\frac{1}{3}x^3\right]_1^5 \\ &= \frac{1}{4} \left[\frac{125}{3} - \frac{1}{3}\right] \\ &= \frac{124}{12} \\ &= \frac{31}{3} \approx 41.3333\end{aligned}$$

og vi får

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \\ &= \frac{31}{3} - 9 \\ &= \frac{31 - 27}{3} \\ &= \frac{4}{3} \end{aligned}$$

Dermed bliver

$$\begin{aligned} \text{Var}(Y) &= \text{Var}(6X + 4) \\ &= 36\text{Var}(X) \\ &= 36 \frac{4}{3} \\ &= 48 \end{aligned}$$

3. Vi har transformationen $t(x) = \log(6x + 4)$ og

(a) $p(x) = \frac{1}{4}\mathbf{1}(x \in [1, 5]), x \in [1, 5]$

(b) grænserne $v = \log(10) \approx 2.30$ og $h = \log(34) \approx 3.53$

(c) $t^{-1}(z) = (e^z - 4)/6$

(d) $\frac{\partial t^{-1}(z)}{\partial z} = \frac{1}{6}e^z$

således at vi har for $z \in (2.30, 3.53)$ at $q(z) = \frac{1}{4}\mathbf{1}((e^z - 4)/6 \in [1, 5])\frac{1}{6}e^z$, hvor indikator-funktionen altid er 1 for $z \in (2.30, 3.53)$. Vi får altså

$$q(z) = \begin{cases} \frac{1}{24}e^z & \text{hvis } z \in (2.30, 3.53) \\ 0 & \text{hvis } z \notin (2.30, 3.53) \end{cases}$$

Opgave 3

1. Vi har, at likelihood bidraget for hver borger er $\ell(\theta|x_i) = p(x_i) = \frac{\theta^{2x_i}}{x_i!} \exp(-\theta^2)$ og log-likelihood bidraget er $\log(\ell(\theta|x_i)) = 2x_i \log(\theta) - \theta^2 - \log(x_i!)$. Log-likelihood funktionen

bliver, grundet uafhængighed mellem borgerne, således

$$\begin{aligned}\log L_n(\theta) &= \log L(\theta|x_1, \dots, x_{251}) = \sum_{i=1}^n \log(\ell(\theta|x_i)) \\ &= \sum_{i=1}^n [2x_i \log(\theta) - \theta^2 - \log(x_i!)] \\ &= -n \cdot \theta^2 + 2 \log(\theta) \sum_{i=1}^n x_i - \sum_{i=1}^n \log(x_i!)\end{aligned}$$

2. Første ordens betingelsen (FOC) for den givne model er at scoren skal være nul,

$$S(\hat{\theta}) = \left. \frac{\partial \log L_n(\theta)}{\partial \theta} \right|_{\theta=\hat{\theta}} = 0$$

hvor vi her har at

$$\begin{aligned}\frac{\partial \log L_n(\theta)}{\partial \theta} &= \sum_{i=1}^n \frac{\partial \log(\ell(\theta|X_i))}{\partial \theta} \\ &= \sum_{i=1}^n s_i(\theta) \\ &= \sum_{i=1}^n \left[\frac{2X_i}{\theta} - 2\theta \right] \\ &= -2n\theta + \sum_{i=1}^n \frac{2X_i}{\theta}\end{aligned}$$

således at maximum likelihood **estimatoren**, $\hat{\theta}_X$, kan findes som løsningen til ligningen

$$\begin{aligned}-2n\hat{\theta}_X + \sum_{i=1}^n \frac{2X_i}{\hat{\theta}_X} &= 0 \\ \Downarrow & \\ n\hat{\theta}_X^2 &= \sum_{i=1}^n X_i \\ \Downarrow & \\ \hat{\theta}_X &= \sqrt{\frac{1}{n} \sum_{i=1}^n X_i}\end{aligned}$$

(hvor vi bruger, at parameter-rummet for θ er $\Theta = \{\mathbb{R} : \theta > 0\}$, hvorfor vi kan ignorere

løsningen $-\sqrt{\frac{1}{n} \sum_{i=1}^n X_i}$.

Ved at bruge $n = 251$ og $\frac{1}{251} \sum_{i=1}^{251} x_i = 2.291$ kan vi udlede **estimatet** for vores data som

$$\begin{aligned}\hat{\theta}_x = \hat{\theta}(x_1, \dots, x_{251}) &= \sqrt{\frac{1}{251} \sum_{i=1}^{251} x_i} \\ &= \sqrt{2.291} \\ &\approx 1.514\end{aligned}$$

3. Hesse-matricen er en skalar i dette tilfælde og givet ved den anden-afledte. Vi får at bidraget for borger i er

$$H_i(\theta) = \frac{\partial^2 \log(\ell(\theta|X_i))}{\partial^2 \theta} = \frac{\partial s_i(\theta)}{\partial \theta} = -\frac{2X_i}{\theta^2} - 2$$

og dermed er informationen

$$\begin{aligned}I(\theta_0) &= \mathbb{E}(-H_i(\theta_0)) \\ &= \mathbb{E}\left(\frac{2X_i}{\theta_0^2} + 2\right) \\ &= 2\frac{\mathbb{E}(X_i)}{\theta_0^2} + 2 \\ &= 2\frac{\theta_0^2}{\theta_0^2} + 2 \\ &= 4\end{aligned}$$

Variansen bliver således

$$\begin{aligned}Var(\hat{\theta}_X) &= \frac{1}{n} I(\theta_0)^{-1} \\ &= \frac{0.25}{n} \\ &\approx 0.00099\end{aligned}$$

Det ses at standardafvigelsen bliver $se(\hat{\theta}_X) = \sqrt{Var(\hat{\theta}_X)} = \sqrt{0.00099} \approx 0.0316$.

4. Vi kan bruge den estimerede model til at beregne sandsynligheden for at en borger

sender mindst én ansøgning

$$P(X_i > 0) = 1 - P(X_i \leq 0) = 1 - \frac{\hat{\theta}^{2 \cdot 0}}{0!} \exp(-\hat{\theta}^2) = 1 - \exp(-1.514^2) \approx 0.8989$$

5. Log-likelihood funktionen for den betingede model er

$$\begin{aligned} \log L_n(\theta, \delta) &= \log L(\theta, \delta | x_1, \dots, x_{251}, d_1, \dots, d_{251}) \\ &= \log \left(\prod_{i=1}^{251} \frac{(\theta + \delta d_i)^{2x_i}}{x_i!} \exp(-(\theta + \delta d_i)^2) \right) \\ &= \sum_{i=1}^{251} \{2x_i \log(\theta + \delta d_i) - (\theta + \delta d_i)^2 - \log(x_i!)\} \end{aligned}$$

6. Hvis $\delta \neq 0$ så er der en tendens til at forsøget påvirker antallet af ansøgninger. Hvis $\delta > 0$ så er der en tendens til at deltagelse i forsøget får borgerne til at sende flere ansøgninger.

7. Vi kunne estimere den betingede model i STATA ved at skrive
`mlexp (2*x*log({theta}+{delta}*d) -({theta}+{delta}*d)^2)`

8. Vi skal teste om der er en signifikant effekt af forsøget. Det svarer til hypotesen

$$\mathcal{H}_0 : \delta = 0$$

med alternativ-hypotesen

$$\mathcal{H}_A : \delta \neq 0.$$

Vi beregner vores z -statistik som

$$z_n(\delta = 0) = \frac{\hat{\delta} - 0}{se(\hat{\delta})} = \frac{0.1411508}{0.063545} \approx 2.2212731.$$

Vi ved at $z_n(\delta = 0) \stackrel{a}{\sim} \mathcal{N}(0, 1)$ under \mathcal{H}_0 . Så vi kan beregne den kritiske værdi på et 5% signifikans-niveau, $\alpha = 0.05$, som $c = \Phi^{-1}(0.975) \approx 1.96$ (to-sidet test). Da $z_n > |c|$ kan vi afvise på et 5% signifikansniveau, at der IKKE er en effekt af forsøget. (p -værdien er $2 \cdot (1 - \Phi(2.221)) \approx 0.026$, hvilket er lavere end de 5%)

Alternativt kan LR-test benyttes da vi har fået log-likelihood funktionen under en restriktede og urestriktede model. Her får vi LR-statistikken

$$LR(\delta = 0) = 2(-95.916305 + 98.372667) = 4.9127$$

og vi ved at under \mathcal{H}_0 , så er $LR \sim \chi_1^2$ med 1 frihedsgrad. Den kritiske værdi er således $F_{\chi_1^2}^{-1}(0.95) = 3.84$. Da $LR(\delta = 0) > 3.84$ kan vi her også afvise at der IKKE er en effekt af forsøget. p-værdien bliver næsten den samme $1 - F_{\chi_1^2}(4.9127) \approx 0.0263$.